

Biostatistiques

Contrôle continu n°2

Sujet

Vous venez d'être recruté(e) comme data analyst / data scientist. Votre première mission va consister à faire parler un petit tableau de données hydrologiques : 10 mesures ont été effectuées sur 31 stations en juin puis en septembre.

Le fichier "Hydrol.txt" contient les colonnes suivantes :

- Station
- Mois (Juin ou Septembre)
- pH ;
- Conductivity ($\mu\text{S}/\text{cm}$) ;
- Carbonate (water hardness ($\text{mg}/\text{l CaCO}_3$)) ;
- Hardness (total water hardness ($\text{mg}/\text{l CaCO}_3$)) ;
- Bicarbonate (alcalinity ($\text{mg}/\text{l HCO}_3^-$)) ;
- Chloride (alcalinity ($\text{mg}/\text{l Cl}^-$)) ;
- Suspens (particles in suspension (mg/l)) ;
- Organic (organic particles (mg/l)) ;
- Nitrate (nitrate rate ($\text{mg}/\text{l NO}_3^-$)) ;
- Ammonia (amoniac rate ($\text{mg}/\text{l NH}_4^-$))

Le fichier "HydrolJuxt.txt" contient exactement les mêmes données, mais les données relatives aux mois de juin et septembre ont été juxtaposées (une ligne par station).

Consignes

• Sauf exceptions, ce travail doit être fait en **binôme**. Ne **postez le travail** que **sur un seul compte**. Indiquez le nom de la personne avec qui vous êtes en binôme dans les commentaires du rendu Moodle.

• Vous devez remettre sur Moodle **trois fichiers en format pdf** :

- 1 fichier "**Rapport**" de 2 pages maximum (police et taille de police : le texte doit être lisible facilement au format A4 sans zoomer)

- 1 fichier "**Figures**" (en pdf) contenant les figures référencées dans le texte. Longueur non limitée. Les légendes permettent de lire la figure mais les descriptions et explications éventuelles doit se trouver dans le fichier "Rapport".

- 1 fichier "**Codes R**" également en pdf.

- Structure du fichier "Rapport" :

- Ne pas écrire d'introduction sur la thématique : entrez directement dans le vif.

- **1. Stratégie d'analyse** : le lecteur doit savoir à quelles questions vous allez tenter de répondre et dans quel ordre (environ 1 à 10 lignes).

- **2. Résultats** (organisés dans l'ordre présenté en 1). Le lecteur doit savoir quelle analyse vous utilisez, les résultats, vos interprétations...

- **3. Conclusion** générale récapitulant, en langage non statistique, les informations qui sont ressorties de vos analyses (environ 10 à 20 lignes).

Ressources

- Vos cours et TD

- Manuels de biostatistiques

- Fichiers d'aides des packages de R

- Moteurs de recherche internet

- Vos IA préférées

Notation et critères envisagés

Rapport (environ 10 points).

- Rédaction : clarté, concision, pertinence.

- Analyses stats : pertinence des choix

- Résultats : qualité des interprétations.

Graphiques (environ 6 points).

Codes (4 points). Critères :

- le code fonctionne-t-il ?

- pertinence des commentaires (#)

Points de bonus : en fonction de votre virtuosité (mais restez pertinents : ne faites pas une analyse inutile simplement pour montrer que vous savez la faire).

Les données utilisées sont dérivées du dataset "buech" du package "ade4" de R.

