

Exercice 1 (10 points) : Des Alignement et de la Phylogénie




Figure 1 : La méthode Clustal W utilise un arbre guide (A) pour calculer un alignement multiple. L'alignement multiple est ensuite utilisé par des méthodes de phylogénie moléculaire, ici Neighbor-Joining (NJ) pour produire un arbre phylogénétique (B).

La distance de Hamming entre deux séquences de même longueur, s et t , est le nombre de positions où les caractères (lettres, symboles, etc.) des deux séquences sont différents. En d'autres termes, elle mesure le nombre de différences directes entre les deux séquences.

1. Cette distance est utilisée pour calculer une matrice de distance afin de construire l'arbre UPGMA en Figure 1-A. **Combien de valeurs est-il nécessaire de calculer ? D'après cet arbre, quels sont les espèces qui produisent les trois plus petites valeurs dans la matrice de distance ?**

- Écrivez les arbres Fig.1-A et Fig.1-B sous format Newick (sans valeur de distances. ni support). Quelle convention pouvez-vous prendre afin d'identifier les différences de topologie entre ces deux arbres ? Quelles sont-elles ?
- À partir de l'arbre Fig.1.B obtenu par NJ, quelles sont maintenant les deux espèces les plus proches ?
- Proposez et justifiez les espèces utilisées pour enraciner l'arbre par mid-point rooting.
- Les arbres de la Fig.1 sont obtenus à partir des séquences du gène XYZ chez les mammifères. Quelle nouvelle espèce proposez vous d'ajouter comme out group pour enraciner l'arbre et sous quelle condition est-ce possible ?

Exercice 2 (5 points) : Des requête et du BLAST

- Que cherche la requête suivante sur la base de donnée "gene": "(rRNA methyl-transferase[fn] OR rRNA methylase[fn]) AND Bacteria[orgn]". Indication sur les champs utilisés: gene full name [fn], organism [orgn]
- Vous avez lancé une requête sur la base de données protein avec ' (IGF1[Gene] AND growth[Description]' et obtenu 500 résultats. Vous remarquez que beaucoup de protéines retournées sont impliquées dans la croissance chez les plantes. Vous devez limiter votre recherche aux séquences protéiques liées à la croissance chez l'homme uniquement. Quelle requête utiliseriez-vous ?

3. L'alignement d'une recherche blastx (DNA → PROT) donne les résultat suivant :

Score	Expect	Identities	Positives	Gaps	Frame
314 bits(805)	9.00E-107	147/192(77%)	168/192(87%)	0/192(0%)	+1
Query 1	MMLTGIDILFSNIIKLSHSIFRQVVEPGDTIVDATCGNGKDALFLAQLLRGKGHLVVYDI				180
	MML GIDILFSNII+LSH++F+QVVEPGD +VDAT GNGKD+LFLA+LL+G+G LVVYDI				
Sbjct 1	MMLKGIDILFSNIIIRLSHAVFQQVVEPGDVVVDATGGNGKDSLFLARLLQGRGRLVVYDI				60
Query 181	QQEALDRATANFQSGLLAEERAI IEMKLCSEHYLQEQQAKLFHYNLGYLPSGDKQITTCS				360
	QQEALDRA F+ L +ER II MK CSHEYLQE+GAKLFHYNLGYLP GDKQITTC				
Sbjct 61	QQEALDRARNLFKEKELSPQERMI I TMKHCSEHYLQEEGAKLFHYNLGYLPCGDKQITTCK				120
Query 361	ESTVTSIYKALELVAPSGIVSVVCYPGHQEGAAELCCVEQVAADLDPSMWEVCTHYSVNR				540
	ST+ S+ KAL+LVA SG+VSVVCYPGH+EGA EL CVEQ+A +LDPS W+VCTHYSVNR				
Sbjct 121	TSTIASLQKALQLVARSGVSVVCYPGHEEGARELLCQEQLAVNLDPSNWDVCTHYSVNR				180
Query 541	RNAPRLFLFRRR				576
	+NAPRLFLFRRR				
Sbjct 181	KNAPRLFLFRRR				192

Quel est la longueur de la séquence de départ de cette requête ?

Peut-on savoir combien de paire de bases sont alignées ?

Quelle information nous donne la valeur 'Frame' de l'alignement ?

Exercice 3 (5 points) : Des séquences et du Python

On considère deux chaînes de caractères **sequence seq** et **dinucléotide dint** (deux bases qui se suivent) et on veut déterminer à quelles positions on retrouve dinucléotide.

- Ecrire la fonction nombreDinucleotide(seq,dint) qui renvoie le nombre de fois où le dinucléotide dint est trouvé dans la séquence.

Par exemple, `nombreDinucleotide("AAAT", 'AA')` renverra 2, et `nombreDinucleotide("AAAT", 'AT')` renverra 1.

2. Ecrire une fonction `ListeOccurence(seq,dint)` qui renvoie la liste des occurrences des dinucléotides `dint`. On considérera pour chaque dinucléotide la position de la première base.
3. Pour la séquence « AAGTCATCA », énumérez la liste des dinucléotides possibles. Pour une séquence de taille n , déduisez la formule pour calculer le nombre total des dinucléotides possibles.
4. Ecrire la fonction `PourcentageDinucleotide(seq,dint)` qui calcule le pourcentage de `dint` par rapport au nombre total de dinucléotides possibles.