

Remarques :

- Les deux sujets sont indépendants et à traiter sur des copies séparées.
- Il sera tenu compte de la qualité de rédaction et de présentation

Sujet 1 (10 points):

Ce sujet est inspiré de la publication suivante :

From vineyard to genome: optimized enrichment and sequencing of Flavescence dorée phytoplasma from grapevine samples. Kogej Zwitter Z, Kutnjak D, Mehle N. *Microb Genom.* 2025 Sep;11(9):001514. doi: 10.1099/mgen.0.001514.

Les phytoplasmes sont des bactéries intracellulaires obligatoires non cultivables qui causent des pertes économiques considérables en agriculture. Le séquençage de leur génome apporte des informations cruciales sur leur biologie et leur dépendance aux insectes vecteurs qui assurent leur transmission de plante à plante. Cependant, les études génomiques sur les phytoplasmes sont souvent entravées par leur faible abondance dans les plantes naturellement infectées. La propagation sur des plantes expérimentales est généralement nécessaire, mais elle est longue et coûteuse en ressources, notamment pour les phytoplasmes de quarantaine comme celui responsable de la flavescence dorée (FD) de la vigne (*Vitis vinifera*), une menace sérieuse pour la viticulture européenne. Afin de surmonter ces difficultés, les auteurs ont développé un protocole d'enrichissement efficace de l'ADN de phytoplasmes directement à partir d'échantillons prélevés sur le terrain, permettant le séquençage de leur génome à l'aide des plateformes Illumina et Oxford Nanopore Technologies.

- 1) D'après ces éléments introductifs, quels sont les principaux défis que représentent le séquençage et l'assemblage de novo du génome du phytoplasme de la Flavescence Dorée ? Justifiez votre réponse (2 points).

Comparaison de différents protocoles de séquençage des phytoplasmes. Afin de déterminer comment enrichir de manière fiable et rapide les phytoplasmes et obtenir leurs séquences génomiques à partir d'un échantillon de vigne prélevé en plein champ (D933/20), des aliquotes de l'échantillon homogénéisé ont été analysées selon six protocoles différents (nommés protocoles A à F). Dans ces protocoles, chaque étape a été ajoutée successivement afin d'évaluer son impact sur le résultat final. Les étapes de chaque protocole sont détaillées ci-dessous.

- DNA extraction with KingFisher (ThermoScientific, USA) and Illumina sequencing
- DNA extraction with CTAB* and Illumina sequencing
- differential centrifugation, DNA extraction with CTAB and Illumina sequencing

- D. differential centrifugation, DNA extraction with CTAB, enrichment with NebNext Microbiome DNA Enrichment Kit (New England Biolabs, MA, USA) and Illumina sequencing
- E. differential centrifugation, DNA extraction with CTAB, enrichment with NebNext Microbiome DNA Enrichment Kit (New England Biolabs, MA, USA), whole-genome amplification (WGA) and Illumina sequencing
- F. differential centrifugation, DNA extraction with CTAB, enrichment with NebNext Microbiome DNA Enrichment Kit (New England Biolabs, MA, USA), WGA and ONT sequencing.

(*) le CTAB est un détergent utilisé fréquemment dans les protocoles d'extraction d'ADN de plantes.

Les résultats de production de données de séquençage obtenues par les différents protocoles sont comparés Tableau 1.

Protocol	A	B	C	D	E	F
DNA concentration (ng μl^{-1})	3.9	28.0	2.2	2.4	386.0	
Total DNA yield (ng)	784	2,800	216	118	11,580	
18S rRNA assay (Cq)	19.1	17.3	21.7	26.0	19.4	
16SrV-specific assay (Cq)	28.9	25.0	28.3	27.3	18.9	
Total nt (billion)	6.1	4.8	4.9	6.0	7.0	7.4
Subsampled total nt (billion)	4.8	4.8	4.8	4.8	4.8	4.8
Nt mapped to host (%)	95.84	96.02	93.89	89.53	91.27	92.48
Nt mapped to FD ref (%)	0.03	0.04	0.07	0.26	0.17	0.15
Consensus length (FDp)	547,983	501,505	576,564	653,574	650,919	653,544
Fraction of FDp ref covered	0.84	0.77	0.88	1.00	1.00	1.00
Average depth (FDp)	3	3	5	19	12	10

Tableau 1. Résultats des tests spécifiques et des analyses bioinformatiques sur l'échantillon de vigne D933/20 préparé selon différents protocoles (A–F) ; rendement en ADN mesuré après isolement et enrichissement (le cas échéant) ; valeurs Cq moyennes de deux réplicats techniques pour des tests PCR en temps réel de l'ARNr 18S et l'ARNr 16S ; taille totale du jeu de données de séquençage en milliards de nucléotides, sous-échantillonné en cinq réplicats à la plus petite taille de jeu de données pour comparaison ; les résultats de cartographie (mapping) des lectures obtenues par séquençage représentent la moyenne de cinq réplicats, chacun sous-échantillonné à 4,8 milliards de nucléotides et cartographié sur le génome hôte (*Vitis vinifera*, GCF_000003745.3) et le génome de référence du phytoplasma FDp (CP097583) ; la longueur de la séquence consensus correspond au consensus basé sur la cartographie.

Afin d'évaluer la qualité de l'ADN qu'ils ont extrait dans les différents protocoles, les auteurs réalisent un mapping des reads sur le génome de référence de la vigne et sur le génome de référence du phytoplasme FD. Les résultats sont indiqués Tableau 1.

- 2) En quoi cette stratégie de mapping est informative pour choisir le meilleur protocole ? (2 points)
- 3) Quel(s) est (sont) le(s) protocole(s) qui vous semble(nt) les plus efficaces pour produire un génome de phytoplasme FD de bonne qualité ? Justifiez votre réponse. (2 points)

Afin de déterminer le nombre minimal de lectures nécessaire pour obtenir un assemblage de bonne qualité, les auteurs évaluent la fraction de génome de phytoplasme FD couverte par mapping avec différents sous-échantillons issus de l'ensemble des lectures produites par les différents protocoles. Les résultats sont présentés Figure 1.




Figure 1. Analyse de raréfaction montrant les résultats de cartographie (mapping) pour 6 tailles de sous-échantillons différentes (0,9, 1,8, 2,4, 3, 3,6 et 4,8 milliards de nucléotides) et 6 protocoles de préparation d'échantillons comparés (A à F, couleurs selon la légende). Pour chaque combinaison protocole/taille de sous-échantillon, l'analyse a été réalisée en cinq réplicats (chaque point représente le résultat d'un réplicat). (a) Proportion du génome de référence FDP couverte en fonction de la taille du sous-échantillon. (b) Profondeur moyenne de couverture du génome de référence FDP en fonction de la taille du sous-échantillon.

- 4) A partir de ces résultats, et sachant que dans le cas de séquençage Illumina, le séquençage réalisé est de type paired-end 2 X 150b, quel vous semble être le nombre minimal de lectures nécessaire pour assurer une bonne couverture du génome du phytoplasme ? Expliquez votre réponse en précisant sur quel protocole vous vous appuyez pour faire ce calcul. (2 points)

- 5) Avec ce nombre minimal de lectures, quelle profondeur de couverture moyenne pouvez-vous espérer ? Cela vous semble-t-il suffisant pour assurer un assemblage final fiable du génome du phytoplasme ? Justifiez votre réponse. (2 points)

Sujet 2 (10 points):

Exercice 1 : QC et Analyse de figures (4 pts)

1. Contrôle de la qualité (QC) des fichiers FastQ (1pt)


Question 1 : Pourquoi le contrôle de la qualité est-il crucial en séquençage de nouvelle génération (NGS) ?

- A. Il augmente la vitesse du séquençage
- B. Il garantit une détection précise des variants
- C. Il réduit le nombre d'échantillons nécessaires
- D. Il simplifie l'analyse des données

Question 2 : Lequel des éléments suivants n'est PAS couramment utilisé pour évaluer la qualité des fichiers FastQ ?

- A. Scores de qualité par base
- B. Teneur en GC
- C. Répartition de la longueur des lectures
- D. Technique de préparation de l'échantillon

2. Trimming des fichiers FastQ (1pt)




Les figures ci-dessus représentent la répartition de la qualité des bases avant et après filtrage ou trimming des lectures (reads) .

Les boxplots A et B portent sur le même nombre de lectures si :

- (a) Le trimming utilisé est « adaptatif, coté 3' » : Vrai/Faux
- (b) Le filtrage utilisé est « filtrage par qualité minimale des reads » : Vrai/Faux
- (c) Le trimming utilisé est « adaptatif, coté 3 ET 5' » : Vrai/Faux

3. GC content (2pts)




La figure ci-dessus représente les courbes de contenu en GC des échantillons issus de l'expérience A en vert et B en orange.

1. Si on estime que les lectures couvrent de manière égale et aléatoire le ou les génomes de chaque expérience, les expériences A et B portent-elles sur les mêmes organismes ? Justifiez votre réponse.
2. Si on cherche à isoler un seul organisme dans chaque expérience, quelle(s) expérience(s) est, ou sont, un succès ? Laquelle ou lesquelles sont un échec ? Justifiez vos réponses.

Exercice 2 : Des problèmes d'alignement (6pts)

1. L'alignement (mapping) des lectures de certains échantillons peut représenter certains challenges. Un premier challenge est représenté dans la figure ci-dessous :




- (a) Que peuvent représenter les parties discontinues en bleu de la séquence de référence, et quel est le processus biologique à l'origine de ce challenge ?
- (b) Quel type de séquençage s'agit-il (ADN, ARN) ?

2. Un deuxième défi pour l'alignement est la présence de délétions ou de duplications de matériel génétique dans les échantillons portant de grands réarrangements chromosomiques.

(c) Quels sont les tissus contenant de tels variants et quel type de séquençage est utilisé pour les détecter (ADN, ARN) ?

Dans l'article Olshen et al. (2004), une méthode statistique particulière (CBS) est utilisée pour détecter de tels réarrangements. L'une des figures issues de l'article est la suivante :



Cette figure analyse la lignée cellulaire fibroblastique GM05296, qui présente des altérations connues uniquement sur les chromosomes 10 et 11. Les points représentent des rapports logarithmiques normalisés $\log_2(T/R)$, et les lignes correspondent aux valeurs moyennes parmi les points dans les segments obtenus par CBS.

(d) Cette méthode semble-t-elle réussir sur la lignée GM05296 ? Si oui, quelles sont les types de réarrangements détectés et où ?

La statistique utilisée ici en ordonnées, est $\log_2(T/R)$ ou T/R est le rapport entre mesure obtenue le long du génome sur les échantillons R et T.

(e) De quels tissus proviennent les échantillons R et T ? Quelle est la mesure utilisée dans le rapport T/R et comment est-elle obtenue avec des données de séquençage ?